


Parecer Técnico

1. Objetivo

O objetivo deste parecer técnico é analisar o desempenho de uma rede neural treinada para classificar frutas em dois estados: verdes e maduros. A rede foi treinada com um conjunto de dados de imagens de frutas, e os resultados foram avaliados através de métricas de acurácia e perda, além de uma visualização das imagens de entrada utilizadas no treinamento.

2. Análise das Imagens




A primeira imagem mostra uma amostra das frutas usadas no treinamento. As frutas apresentadas incluem melão, pepino e maçã, tanto em estágios verdes quanto maduros. Essas imagens foram pré-processadas e redimensionadas para o tamanho de 150x150 pixels, o que permitiu a entrada na rede neural convolucional (CNN).

- **Variedade:** As frutas variam em tamanho, formato e textura, fornecendo uma boa diversidade para o modelo aprender características relevantes para a classificação.

- **Qualidade:** As imagens apresentam boa qualidade visual, o que facilita a extração de características como bordas e contornos.

3. Análise dos Gráficos de Acurácia e Perda



A segunda imagem apresenta os gráficos de acurácia e perda ao longo das épocas de treinamento e validação.

- **Acurácia de Treinamento e Validação:** A acurácia do treinamento aumentou ao longo das épocas, atingindo quase 100% no final. No entanto, a acurácia de validação apresentou variação e estabilizou-se em torno de 73,5%. Essa diferença indica que o modelo pode estar superajustado aos dados de treinamento, não generalizando bem para os dados de validação.
- **Perda de Treinamento e Validação:** A perda de validação aumentou significativamente ao longo das épocas, enquanto a perda de treinamento diminuiu. Esse comportamento reforça a suspeita de overfitting, onde o modelo está aprendendo muito bem os dados de treino, mas não consegue generalizar para novos dados.

4. Conclusão

Os resultados mostram que o modelo está tendo um bom desempenho no conjunto de treinamento, mas sua capacidade de generalização para o conjunto de validação precisa ser melhorada. Recomendações para melhorar o modelo incluem:

- Aumentar o dataset: Mais imagens podem melhorar a capacidade do modelo de generalizar.
- Aplicar técnicas de data augmentation: Rotacionar, espelhar e aplicar outras transformações nas imagens de treino pode ajudar a reduzir o overfitting.
- Ajustar os hiperparâmetros: Reduzir o número de épocas ou ajustar a taxa de aprendizado pode melhorar a performance de validação.

AUTOR:

Izairton O de Vasconcelos

https://github.com/IOVASCON/IoT_Neuralis_Artificiais.git